Подсказка по регулярным выражениям

Шпаргалка с кратким содержанием:

- . Один любой символ, кроме новой строки \n.
- ? 0 или 1 вхождение шаблона слева
- 1 и более вхождений шаблона слева
- * 0 и более вхождений шаблона слева
- \w Любая цифра или буква (\W все, кроме буквы или цифры)
- \d Любая цифра [0-9] (\D все, кроме цифры)
- \s Любой пробельный символ (\S любой непробельный символ)
- **\b** Граница слова
- [..] Один из символов в скобках ([^..] любой символ, кроме тех, что в скобках)
- \ Экранирование специальных символов (\. означает точку или \+ знак «плюс»)
- ^ и \$ Начало и конец строки соответственно
- **{n,m}** От n до m вхождений (**{,m}** от 0 до m)
- **a** | **b** Соответствует а или b
- () Группирует выражение и возвращает найденный текст
- \t, \n, \r Символ табуляции, новой строки и возврата каретки соответственно

Описание шаблонов

В столбце "Применение выражения к тексту" соответствия регулярному выражению выделяются бирюзовым цветом с подчёркиванием.

Источник (и бонусом - отличная статья по RegExp):

https://habr.com/ru/post/349860/#Regulyarki

Шаблон	Описание	Пример выражения	Применение выражения к тексту
	Один любой символ, кроме новой строки \n.	м.л.ко	<u>молоко, малако,</u> И <u>м0л0ко</u> Ихлеб
\d	Любая цифра	CY\d\d	<u>СУ35, СУ11</u> 1, АЛ <u>СУ14</u>
\D	Любой символ, кроме цифры	926\D123	<u>926)123</u> , 1 <u>926-123</u> 4

\s	Любой пробельный символ (пробел, табуляция, конец строки и т.п.)	бор\ѕода	<u>бор ода, бор</u> <u>ода,</u> борода
\S	Любой непробельный символ	\S123	<u>X123, я123, !123</u> 456, 1 + 123456
\w	Любая буква (то, что может быть частью слова), а также цифры и	\w\w\w	Год, f <u>3</u> , qwert
\W	Любая не-буква, не-цифра и не подчёркивание	COM/W	сом!, сом?
[]	Один из символов в скобках, а также любой символ из диапазона a-b	[0-9][0-9A-Fa-f]	12, 1F, 4B
[^]	Любой символ, кроме перечисленных	<[^>]>	<u><1>, <a>,</u> <>>
[abc-],	если нужен минус, его нужно указать последним или первым		
\b	Начало или конец слова (слева пусто или не-буква, справа буква и наоборот). В отличие от предыдущих соответствует позиции, а не символу	\bвал	<u>вал,</u> перевал, Перевалка
\B	Не граница слова: либо и слева, и справа буквы, либо и слева, и справа НЕ буквы	\Ввал	пере <u>вал,</u> вал, Пере <u>вал</u> ка

		\Ввал\В	перевал, вал, Пере <u>вал</u> ка
? +? ?? {m,n}? {,n}? {m,}?	По умолчанию квантификаторы жадные — захватывают максимально возможное число символов. Добавление ? делает их ленивыми, они захватывают минимально	\(.\)	(a + b) * (c + d) * (e + f) (a + b) * (c + d) * (e + f)
	возможное число символов		

Квантификаторы (указание количества повторений)

Шаблон	Описание	Пример выражения	Применение выражения к тексту
{ n }	Ровно n повторений	\d{4}	1, 12, 123, <u>1234</u> , 12345
{m,n}	От m до n повторений включительно	\d{2,4}	1, <u>12</u> , <u>123</u> , <u>1234</u> , 12345
{m,}	Не менее т повторений	\d{3,}	1, 12, <u>123</u> , <u>1234</u> , <u>12345</u>
{ , n }	Не более n повторений	\d{,2}	<u>1, 12, 12</u> 3
?	Ноль или одно вхождение, синоним {0,1}	валы?	<u>вал,</u> <u>валы,</u> <u>вал</u> ов
*	Ноль или более, синоним { 0, }	CY\d*	СУ, СУ1, СУ12,
+	Одно или более, синоним {1,}	a\)+	<u>a), a)), a))),</u> b <u>a)]</u>)

Группы в регулярном выражении

При решении различных задач также часто используются круглые скобки (...) Их значение заключается в двух функциях:

1) Эти скобки призваны сократить повторяющиеся группы внутри шаблонов.

Пример: МАС-адрес сетевого устройства обычно записывается как шесть групп из двух шестнадцатеричных цифр, разделённых символами '-' или ':'

01:23:45:67:89:ab

Без применения скобочных групп шаблон будет выглядеть так:

Сгруппировав повторяющиеся части, можно с помощью квантификаторов задать количество их повторов:

```
pattern = r'[0-9a-fA-F]{2}(?:[:-][0-9a-fA-F]{2}){5}'
```

Что даже на таком простом примере позволило значительно сократить размер регулярного выражения.

Ещё одна сильная сторона подобных группировок в том, что теперь мы можем писать шаблон даже не зная точного количества групп, ведь в квантификаторе можно указать не только точное число, **но и отрезок**, на котором оно должно находится

2) Используя скобки (...) с функциями re.search(), re.fullmatch() и re.finditer() в возвращенных match-объектах мы сможем получить доступ к информации по каждой группе, выделенной скобками, отдельно (часть подстроки, которая совпала этой группой и индексы)

Пример:

```
pattern = r'\s*([A-Яа-яЁё]+)(\d+)\s*'
string = r'--- Опять45 ---'
matched = re.search(pattern, string)

print('Совпадение вернулось объектом', matched) # re.Match object
```

match[0] в обычном случае работает так же, как и match.group()
Но теперь с помощью match[1] и match[2] мы можем вернуть подстроки, совпадающие с первой группой - ([А-Яа-яЁё]+) - это 'Опять' и со второй (\d+) - это '45'

```
print(f'Найдена подстрока >{matched[0]}< с позиции {matched.start(0)} до {matched.end(0)}')

# Найдена подстрока > Опять45 < с позиции 3 до 16

print(f'Группа букв >{matched[1]}< с позиции {matched.start(1)} до {matched.end(1)}')

# Группа букв >Опять< с позиции 6 до 11

print(f'Группа цифр >{matched[2]}< с позиции {matched.start(2)} до {matched.end(2)}')

# Группа цифр >45< с позиции 11 до 13</pre>
```

Более подробно про группы в регулярных выражениях можно почитать в вышеупомянутой статье, в разделе "Группирующие скобки": https://habr.com/ru/post/349860/#Gruppiruvuschie_skobki

Полезные ссылки

Официальная документация: https://docs.python.org/3/library/re.html

Также есть отличный сайт для дебага и проверки регулярных выражений, обязательно попробуйте:

https://regex101.com/